Performance on simple inferences vs. GSM-8K score
Temperature: 0, Condition: zero-shot

Model
- GPT-4 Turbo (2024-04-09)
- GPT-4 (0613)
- Claude 3 Opus
- Llama 3 Instruct 70B
- Mixtral 8x7B
- Claude 3 Sonnet
- Llama 3 Instruct 8B
- Claude 3 Haiku
- Phi-2
- Code Llama 13B
- Code Llama 7B
- Code Llama 34B
- Yi Chat 34B